Trabalho de Aplicação - Rio São Franscisco

Yugo Oyama NUSP: 9297784

14/11/2021

Introdução

Este trabalho consiste na aplicação de técnicas estatísticas abordadas no curso de Estatística em Altas Dimensões - 2021 em dois bancos de dados que serão explicados detalhadamente mais a frente.

Chuva e vazão no Rio São Francisco

Dados

Os dados armazenados no arquivo dados_rio_sf.rdata são referentes a medições de vazão e chuva em estações localizadas na região do rio São Francisco.

Dentro deste arquivo, há três variáveis:

treino_sf: conjunto de treino com as medições de vazão e precipitação nas estações consideradas; estacoes: com informações sobre as estações que coletam os dados; teste_sf: conjundo com dados que serão usados para avaliar a performance dos modelos preditivos;

Dados de treinamento

O dataframe dados_treino contem 1717 linhas e 83 colunas. Cada linha contêm medições semanais de vazão em diferentes estações fluviométricas sobre o rio São Francisco e de chuva em estações pluviométricas em regiões próximas do rio. Se a estação é fluviométrica, o dado armazenado é a vazão média registrada na semana correspondente. Caso a estação seja pluviométrica, o dado registrado é a chuva acumulada naquela semana. A primeira coluna, chamada Y, contém a medida de vazão na estação fluviométrica de código 46998000, que corresponde à estação em que se tem interesse em fazer previsão. A vazão na coluna Y corresponde à medição na semana seguinte às demais medições da mesma linha.

Estações

O dataframe estações contém informações sobre cada uma das estações que aparecem no dataframe treino_sf. Essas informações estão disponibilizadas apenas a título de curiosidade e não devem ser utilizadas para construir os modelos preditivos. Por exemplo, latitude e longitude, além do tipo da estação (fluviométrica ou pluviométrica) e outros detalhes técnicos de cada uma delas.

Objetivo

O objetivo desta análise é propor um modelo que consiga realizar boas predições para as medições de vazão na estação 46998000 (coluna Y), dadas as medições tomadas nas estações do sistema na semana anterior (demais colunas).

Técnicas

Para esse projeto serão usados modelos lineares com regularização, modelos baseados em árvores, e redes neurais.

Para comparar os modelos entre si,será utilizado o erro absoluto médio (MAE) e ao final de cada método testado, será adicionado o resultado a uma tabela comparativa.

Parâmetros

Para o ajuste do modelo, foi definido que o conjunto de treino seria dividido em conjunto de treino e validação na proporção 8:2, ou seja, 20% do conjunto originalmente de treino foi usado para validação. Foi definida também uma semente por questão de reprodutibilidade (1234).

Modelo Média

De forma a ter uma base para comparar, foi construído um modelo simples que considera todos os valores da estação 46998000, calcula a média e sempre preve que a próxima medição será a média.

Temos os resultados abaixo.

```
##   modelo erro_dentro erro_fora
## 1  Media    1229.247  1117.671
```

Lasso

Para criar um modelo de regressão com a penalização lasso, foi utilizada a biblioteca glmnet. Com ela, dentro da amostra de treino, foi ajustado o modelo de regressão com penalização lasso utizando validação cruzada. Em seguida, foi testado o modelo obtido no conjunto de validação e calculado o respectivo erro dentro e fora.

Para a escolha do lambda, iniciou-se uma sequência: 0.01, 0.1, 1, 2, 10, 25, 50, 75, 100 e permitiu que a função cv.glmnet escolhesse o melhor lambda. Existem dois lambdas que são popularmentes usados: o que minimiza o erro gerado pela validação cruzada e o no qual o erro não ultrapassa um desvio padrão do melhor modelo. Com isso, foram testados modelos com cada um dos lambdas e calculados os erros dentro e fora respectivos de cada um.

Ainda como modelo alternativo, foi definido que a função cv.glmnet escolhesse 30 lambdas diferentes e ajustasse um modelo.

Os resultados obtidos podem ser observados na tabela a seguir.

```
##                             modelo erro_dentro erro_fora
## 1                            Media   1229.2470 1117.6707
## 2           Lasso - lambda minimo    159.3055  167.9468
## 3  Lasso - lambda 1 desvio padrao    164.7565  171.2722
## 4          Lasso 2- lambda minimo    159.4736  167.9468
## 5 Lasso 2- lambda 1 desvio padrao    165.0675  171.5473
```

Percebemos que em relação ao modelo média, há uma expressiva melhora tanto no erro dentro como no erro fora.

Em relação ao uso do lambda mínimo ou lambda 1 desvio padrão, os resultados são muito semelhantes, sendo que o lambda mínimo obteve um desempenho um pouco melhor.

Em relação a aos modelos com a lista de lambdas fornecidas e com os 30 lambdas escolhidos pela função, os resultudados pbtidos foram muito semelhantes.

Modelo de Floresta Aleatória

Foi escolhido o modelo de Floresta Aleatória já que dessa forma existe variabilidade na escolha das variáveis explicativas e na escolha das observações para a construção de cada árvore. Essa variabilidade por sua vez pode levar a uma melhor predição no conjunto de validação e no de teste.

Para realizar o ajuste do modelo, foi utilizado a função randomForest do pacote randomForest.

Como os nomes das estações são numéricas foi necessário fazer uma pequena alteração para que o comando randomForest funcionasse.

A seguir, podemos ver as cinco estações mais importantes e as cinco menos importantes para a predição.

```
##           IncNodePurity
## V45298000    1292229623
## V46105000     850297391
## V44290002     845926098
## V46998000     491202165
## V42210000     271091061
## V40025000     105445025
```

```
##          IncNodePurity
## V1343008      845293.7
## V1944011      840024.1
## V1544018      737681.6
## V1242015      733611.5
## V1444005      672340.8
```

Ainda, é possível vizualizar melhor no gráfico a seguir a importância de cada estação.

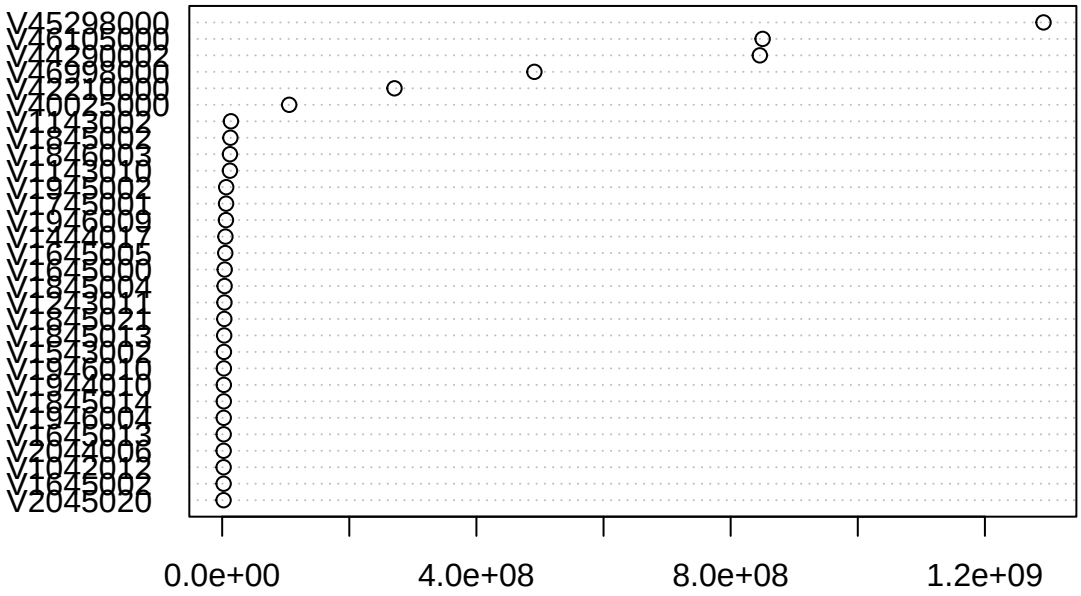

Percebemos claramente pelo gráfico que as estações 45298000,46105000,44290002,46998000,42210000,40025000 são as estações que mais contribuem para a previsão. As outras estações por outro lado contribuem pouco e de forma semelhante para a previsão.

```
##                           modelo erro_dentro erro_fora
## 1                         Media   1229.2470 1117.6707
## 2          Lasso - lambda minimo    159.3055  167.9468
## 3  Lasso - lambda 1 desvio padrao    164.7565  171.2722
## 4         Lasso 2- lambda minimo    159.4736  167.9468
## 5 Lasso 2- lambda 1 desvio padrao    165.0675  171.5473
## 6             Floresta Aleatoria     52.7926  113.4956
```

Novamente, percebemos uma melhora significativa em relação ao modelo média.

Em relação ao modelo de lasso, percebemos melhora expressiva no erro dentro e melhora significativa no erro fora.

Redes neurais

Para o modelo de redes neurais, foi utilizada a função de ativação ReLU ao invés da sigmoid por ser computacionalmente mais rápida.

Vamos considerar um modelo com apenas uma camada oculta e 41 unidades, por corresponder a 50% da quantidade de camadas de entrada e um modelo com 3 camadas ocultas com 60,40,20 unidades respectivamente por corresponderem a aproximadamente 75%, 50%, 25%.

Foram considerados 40% de supressão, 150 epochs e tamanho de batch = 32.

```
## Loaded Tensorflow version 2.5.0
```

Podemos observar os resultados a seguir.

```
##                             modelo erro_dentro erro_fora
## 1                            Media   1229.2470 1117.6707
## 2           Lasso - lambda minimo    159.3055  167.9468
## 3  Lasso - lambda 1 desvio padrao    164.7565  171.2722
## 4          Lasso 2- lambda minimo    159.4736  167.9468
## 5 Lasso 2- lambda 1 desvio padrao    165.0675  171.5473
## 6              Floresta Aleatoria     52.7926  113.4956
## 7                     Rede Neural   2555.8119 2445.9768
## 8                   Rede Neural 2   2551.4031 2422.4802
```

Percebemos que aumentar o numero de camadas ocultas não melhorou o erro de previsão do modelo. Pelo contrário, piorou-a.

Dentre modelos, o que teve melhor desempenho tanto no erro dentro quanto no erro fora foi o modelo de floresta aleatória. Dessa forma, a previsão para os dados de teste foi feita utilizando o modelo de floresta aleatória.